



**TECNOLÓGICO
NACIONAL DE MÉXICO**



TECNOLÓGICO NACIONAL DE MÉXICO Instituto Tecnológico de Culiacán

**Tópicos de Inteligencia Artificial
Unidad 1**

**Inteligencia Artificial aplicada al tratamiento y control de la calidad de
aguas residuales**

MAESTRO:

Zuriel Dathan Mora Félix

ALUMNOS:

Jesús Omar Langarica Ornelas
Jesús Miguel Velarde Arce

CARRERA:

Ingeniería en Sistemas Computacionales

REPOSITORIO: <https://github.com/OmarLangarica/topicos-ia>

Culiacán, Sinaloa, 17 de septiembre de 2026

Índice

1. Introducción	3
2. Objetivos.....	4
2.1 Objetivo General.....	4
2.2 Objetivos Específicos.....	4
3. Justificación	5
4. Alcance.....	6
5. Desarrollo	7
5.1. Descripción del Problema Ambiental	7
5.2. Análisis de las Soluciones Actuales de IA y su Efectividad.....	7
5.3. Propuesta de IA para el Control de la Calidad de Aguas Residuales	8
5.3.1. Definición de Variables del Sistema	8
5.3.2. Construcción del Dataset.....	9
5.3.3. Preprocesamiento y Preparación de Datos	10
5.3.3.1. Limpieza de Datos.....	10
5.3.3.2. Transformación de Variables	11
5.3.4. División del Dataset y Validación	11
5.3.5. Entrenamiento del Modelo de IA.....	11
5.3.6. Evaluación del Modelo	12
5.3.7. Predicción y Clasificación de la Calidad del Agua.....	13
5.3.8. Implementación Futura del Sistema	13
5.4. Impacto Potencial de esta Solución en el Medio Ambiente.....	14
6. Agenda.....	17
7. Conclusiones	18
8. Bibliografía	19

1. Introducción

Hoy en día, el tratamiento de las aguas residuales es un reto ambiental fundamental debido a los contaminantes que, si no se manejan adecuadamente, dañan seriamente los cuerpos de agua. Para asegurar un buen control del proceso de depuración, es necesario revisar constantemente varias características clave del agua, como la Demanda Bioquímica de Oxígeno (DBO), la Demanda Química de Oxígeno (DQO), el pH, los Sólidos Suspendidos Totales (SST), la conductividad y la turbiedad. Sin embargo, los cambios constantes en el agua que ingresa a la planta y en el funcionamiento de esta complican los métodos tradicionales de control.

Ante este panorama, la inteligencia artificial surge como una herramienta sólida para modelar estos sistemas. Al usar técnicas avanzadas como las redes neuronales artificiales y el análisis de datos, es posible procesar una gran cantidad de información histórica para encontrar patrones y relaciones entre las variables operativas que no resultan evidentes a simple vista. Es importante señalar que el objetivo de integrar estas herramientas no es reemplazar los análisis de laboratorio ni los procesos físicos habituales; por el contrario, se busca aplicar modelos predictivos como un sistema de apoyo complementario. Esto ayuda a mejorar el seguimiento de la calidad del agua, anticipar cambios en el sistema y tomar mejores decisiones operativas, asegurando así que el agua tratada cumpla con las normas ambientales.

2. Objetivos

2.1 Objetivo General

Desarrollar un sistema de Inteligencia Artificial orientado al control, monitoreo y predicción de la calidad de las aguas residuales en los procesos de tratamiento.

2.2 Objetivos Específicos

- Definir las variables fisicoquímicas de entrada (DBO, DQO, pH, SST, conductividad y turbiedad) requeridas para el análisis predictivo.
- Construir y preprocesar un conjunto de datos (dataset) a partir de registros históricos obtenidos del funcionamiento de una planta de tratamiento.
- Entrenar y evaluar un modelo de Red Neuronal Artificial de tipo Perceptrón Multicapa (MLP) utilizando el conjunto de datos procesado.
- Generar un modelo de clasificación que permita determinar si las condiciones del efluente corresponden a un estado de cumplimiento ("SÍ_CUMPLE" o "NO_CUMPLE") respecto a la normatividad.

3. Justificación

Los métodos de laboratorio convencionales proporcionan información muy precisa sobre el agua; sin embargo, dada la cantidad de variables fisicoquímicas involucradas y los cambios constantes en las condiciones de entrada a la planta, resulta muy difícil identificar las relaciones entre dichas variables de manera individual. Por ello, es necesario reforzar el control y el monitoreo mediante herramientas tecnológicas que superen esas limitaciones tradicionales.

La aplicación de este sistema de Inteligencia Artificial se justifica, en primer lugar, por su capacidad para detectar problemas a tiempo. Al clasificar los resultados esperados y advertir cuando existe riesgo de incumplimiento normativo (marcando un estado de "NO_CUMPLE"), el modelo reduce el riesgo de que agua mal tratada avance en el proceso o termine descargándose al medio ambiente.

En segundo lugar, desde el punto de vista operativo, estos modelos predictivos ayudan a optimizar la depuración. La herramienta permite simular distintas condiciones de trabajo y evaluar el efecto de las dosis de químicos —como coagulantes y floculantes— antes de realizar modificaciones en la planta física, lo que favorece un mejor aprovechamiento de los recursos.

Por último, al ofrecer un seguimiento continuo y automático de la calidad del agua, el sistema genera datos clave que facilitan la reutilización segura del agua tratada en otras actividades, impulsando una gestión del agua más sostenible y con un impacto ambiental positivo.

4. Alcance

Esta investigación se centra en diseñar, entrenar y evaluar un modelo predictivo basado en Redes Neuronales Artificiales, utilizando una arquitectura de Perceptrón Multicapa para analizar aguas residuales. El trabajo metodológico abarca desde la construcción de un conjunto de datos (dataset) con registros históricos de una planta de tratamiento, hasta la limpieza y preparación de la información usando variables fisicoquímicas clave como la DBO, la DQO, el pH, los SST, la conductividad y la turbiedad. Posteriormente, el modelo se programa y entrena para estimar los parámetros de salida y clasificar si el agua tratada "SÍ_CUMPLE" o "NO_CUMPLE" con la normatividad ambiental.

Asimismo, el proyecto incluye una fase de validación detallada del sistema. Para ello, se evaluará el rendimiento del algoritmo mediante métricas estadísticas como la exactitud, la precisión, el recall y la matriz de confusión. Esta revisión se enfocará especialmente en comprobar qué tan bien el modelo detecta, de forma acertada y oportuna, los momentos críticos en los que el agua no cumple con lo establecido.

Por otra parte, es importante aclarar los límites de la investigación: el sistema funcionará únicamente como una herramienta de apoyo analítico para la toma de decisiones. El proyecto no contempla realizar cambios físicos en la infraestructura o en los procesos de la planta, ni busca reemplazar los análisis de laboratorio convencionales. Finalmente, la conexión de este modelo a sensores o sistemas de hardware para automatizar el monitoreo en tiempo real dentro de las instalaciones tampoco forma parte de esta etapa, quedando reservada como una propuesta a futuro.

5. Desarrollo

5.1. Descripción del Problema Ambiental

El análisis y control de la calidad del agua constituyen un desafío crítico para la gestión ambiental y el cumplimiento normativo. Los métodos tradicionales de monitoreo a menudo presentan limitaciones operativas, debido a los costos asociados, los tiempos de respuesta prolongados en laboratorio y la dificultad para capturar la variabilidad temporal de los cuerpos hídricos.

Para evaluar de forma integral la condición de un efluente o cuerpo de agua, se requiere el seguimiento de parámetros fisicoquímicos fundamentales como la Demanda Bioquímica de Oxígeno (DBO), la Demanda Química de Oxígeno (DQO), el potencial de hidrógeno (pH) y los Sólidos Suspendidos Totales (SST) (Bernal, Simental Martínez, & Cortes Martínez, 2026). Estos indicadores permiten caracterizar el grado de contaminación orgánica, la acidez o alcalinidad y la carga particulada, facilitando la toma de decisiones oportunas para la mitigación de impactos ambientales.

Ante la necesidad de optimizar la gestión de estos recursos, la incorporación de modelos analíticos avanzados se ha vuelto indispensable. Diversas investigaciones demuestran que el uso de enfoques basados en ciencia de datos e inteligencia artificial aporta una perspectiva complementaria para el análisis predictivo y la clasificación del cumplimiento normativo en sistemas hídricos (González-Salcedo & García-Nuñez, 2020). Asimismo, el procesamiento adecuado de los registros históricos de calidad del agua permite identificar patrones complejos y superar las barreras de los métodos convencionales de muestreo (Treviño Cansino, Alcorta García, Espinoza Fraire, Sáenz Esqueda, & Lozoya Vélez, 2018).



Figura 1. Planta de tratamiento de aguas residuales en Sinaloa (CuliacanDigital, 2023)

5.2. Análisis de las Soluciones Actuales de IA y su Efectividad

En la literatura reciente sobre la gestión y evaluación de recursos hídricos destacan dos vertientes metodológicas principales para el tratamiento de datos: la clasificación del

cumplimiento normativo y la predicción numérica de variables críticas (como la turbiedad o la concentración de contaminantes).

Por un lado, la aplicación de técnicas de minería de datos facilita la exploración de grandes volúmenes de registros históricos para identificar tendencias ocultas y agrupar comportamientos similares en las cuencas o efluentes (Bernal, Simental Martínez, & Cortes Martínez, 2026). Esto permite transformar bases de datos dispersas en información estructurada, apta para la toma de decisiones ambientales.

Por otro lado, la implementación de algoritmos de aprendizaje automático, como las redes neuronales artificiales, ofrece la capacidad de modelar relaciones no lineales complejas entre los parámetros fisicoquímicos. Estos modelos predictivos optimizan el seguimiento de la calidad del agua al anticipar fluctuaciones en los cuerpos hídricos, reduciendo la dependencia exclusiva de muestreos físicos frecuentes y costosos (González-Salcedo & García-Nuñez, 2020). De manera complementaria, el análisis riguroso de las fuentes de información y la limpieza de registros inconsistentes resultan etapas fundamentales para asegurar la robustez de cualquier arquitectura predictiva aplicada al sector hídrico (Treviño Cansino, Alcorta García, Espinoza Fraire, Sáenz Esqueda, & Lozoya Vélez, 2018).

5.3. Propuesta de IA para el Control de la Calidad de Aguas Residuales

A partir de la revisión de los enfoques previos, el diseño de un sistema eficiente de evaluación de la calidad del agua requiere una estructuración metodológica rigurosa que conecte la recolección de datos con modelos predictivos y de clasificación operativos (Bernal, Simental Martínez, & Cortes Martínez, 2026). Para lograrlo, la presente propuesta define con claridad las variables de entrada y salida necesarias —los parámetros fisicoquímicos y los límites normativos de cumplimiento—, asegurando un preprocesamiento adecuado que elimine inconsistencias y optimice el rendimiento de los algoritmos de aprendizaje automático. De este modo, se establece un flujo de trabajo automatizado que no solo facilita la interpretación de los resultados, sino que también ofrece una herramienta de apoyo confiable y adaptable para la toma de decisiones en la gestión ambiental.

5.3.1. Definición de Variables del Sistema

Para desarrollar el modelo propuesto es necesario determinar las variables que serán utilizadas como entradas y salidas. La selección se basa principalmente en los parámetros empleados en los estudios revisados y en su relación con la evaluación de la calidad del agua residual. Como variables de entrada se propone utilizar:

- DBO: indicador relacionado con la cantidad de materia orgánica presente en el agua residual.
- DQO: parámetro utilizado para evaluar la cantidad de materia susceptible de oxidación.
- pH: permite identificar las condiciones de acidez o alcalinidad del agua.
- SST: representa la cantidad de sólidos suspendidos presentes en el agua.
- Conductividad eléctrica: relacionada con la presencia de sales disueltas.

- **Turbiedad:** permite representar la cantidad de partículas que afectan la claridad del agua.

Estos parámetros han sido utilizados en investigaciones sobre modelado y análisis de calidad de aguas residuales. En particular, DBO, DQO, pH y SST son señalados como indicadores utilizados para definir la calidad del agua residual, mientras que otros estudios incorporan la conductividad y la turbiedad dentro de sus variables de análisis.

También se propone considerar variables relacionadas con las condiciones de operación de la planta cuando exista disponibilidad de estos datos. En investigaciones anteriores se han utilizado variables como el gasto o caudal, además de nitrógeno y fósforo, para estudiar la eficiencia de depuración y el comportamiento de los sistemas de tratamiento.

Como variable de salida principal se propone una clasificación de la calidad del agua mediante dos categorías:

- **SÍ_CUMPLE:** cuando las condiciones estimadas del agua tratada se encuentran dentro de los límites establecidos para los parámetros considerados.
- **NO_CUMPLE:** cuando al menos una de las condiciones evaluadas supera el límite establecido correspondiente.

Esta estructura toma como referencia el procedimiento utilizado en el estudio de minería de datos, donde se incorporó una variable nominal con las categorías "NO_CUMPLE" y "SÍ_CUMPLE" (Treviño Cansino, Alcorta García, Espinoza Fraire, Sáenz Esqueda, & Lozoya Vélez, 2018). De manera complementaria, el sistema podría generar predicciones numéricas de determinados parámetros —principalmente turbiedad, DBO o DQO— antes de producir la clasificación final. Esto permitiría que el sistema no solamente indique la categoría obtenida, sino que también proporcione información sobre los parámetros que están influyendo en dicha clasificación.

5.3.2. Construcción del Dataset

El desarrollo del modelo requiere construir un conjunto de datos o dataset que contenga información suficiente para que el algoritmo pueda identificar relaciones entre las variables de entrada y la calidad final del agua.

El dataset propuesto estaría compuesto por registros históricos obtenidos de una planta de tratamiento de aguas residuales. Cada registro representaría una observación del proceso, incluyendo las mediciones disponibles de los parámetros de calidad y, cuando sea posible, las condiciones de operación correspondientes. Una estructura inicial del dataset podría organizarse de la siguiente manera:

Variable	Tipo	Función
DBO	Cuantitativa	Entrada
DQO	Cuantitativa	Entrada
pH	Cuantitativa	Entrada
SST	Cuantitativa	Entrada
Conductividad	Cuantitativa	Entrada
Turbiedad	Cuantitativa	Entrada
Caudal	Cuantitativa	Entrada opcional
SÍ_CUMPLE / NO_CUMPLE	Cualitativa (nominal)	Salida

La utilización de variables de entrada para predecir una condición de salida sigue el principio empleado en el estudio basado en WEKA, donde los datos de entrada de la planta fueron utilizados para encontrar una relación con la variable nominal de cumplimiento (Treviño Cansino, Alcorta García, Espinoza Fraire, Sáenz Esqueda, & Lozoya Vélez, 2018).

Como antecedente, uno de los estudios revisados trabajó inicialmente con 526 instancias y 10 atributos y, después del tratamiento de valores faltantes y valores atípicos, obtuvo 493 instancias. Este procedimiento demuestra la importancia de contar con un proceso de preparación de los datos antes de utilizarlos para entrenar un modelo de Inteligencia Artificial.

Para la propuesta de este proyecto, el tamaño definitivo del dataset dependerá de la cantidad de registros disponibles. Se buscará contar con suficientes observaciones para representar diferentes condiciones del proceso de tratamiento y evitar que el modelo aprenda únicamente un comportamiento específico.

5.3.3. Preprocesamiento y Preparación de Datos

Antes de utilizar el dataset para entrenar el modelo de Inteligencia Artificial, será necesario realizar un proceso de preprocesamiento. Esta etapa tiene como finalidad mejorar la calidad de la información y reducir problemas que puedan afectar el aprendizaje del algoritmo.

El preprocesamiento incluirá principalmente la revisión de datos faltantes, valores atípicos, unidades de medición, rangos de las variables y transformación de los datos cuando sea necesario. Esta etapa toma como referencia el procedimiento utilizado en el estudio de minería de datos, en el cual los valores faltantes fueron reemplazados mediante la media para variables continuas y la moda para variables discretas. Posteriormente se identificaron y eliminaron valores atípicos y extremos, reduciendo el conjunto original de 526 a 493 instancias (Treviño Cansino, Alcorta García, Espinoza Fraire, Sáenz Esqueda, & Lozoya Vélez, 2018).

5.3.3.1. Limpieza de Datos

La primera etapa consistirá en identificar registros incompletos, inconsistentes o que puedan representar errores de medición. Los valores faltantes deberán ser identificados para determinar si pueden ser sustituidos mediante un método estadístico o si el registro debe ser descartado. Como referencia, el estudio realizado mediante WEKA utilizó la media para reemplazar valores faltantes continuos y la moda para valores discretos.

También se realizará la identificación de valores atípicos. Estos pueden representar errores de medición, registros excepcionales o condiciones reales del proceso que deben analizarse antes de decidir si se eliminan. En el estudio revisado se utilizó el rango intercuartílico para identificar valores atípicos, y posteriormente se eliminaron determinados registros. Por último, se verificará que todas las variables utilicen unidades consistentes y que los registros correspondan al mismo tipo de medición.

5.3.3.2. Transformación de Variables

Una vez realizada la limpieza, las variables deberán prepararse para ser utilizadas por el modelo de Inteligencia Artificial. Las variables numéricas podrán ser normalizadas o estandarizadas cuando el algoritmo seleccionado lo requiera. Esto permitirá reducir las diferencias de escala entre parámetros como pH, DBO, DQO, SST, conductividad y turbiedad.

La variable de salida será transformada a una representación categórica mediante las etiquetas SÍ_CUMPLE y NO_CUMPLE, tomando como referencia los límites de calidad establecidos para los parámetros seleccionados. Este procedimiento sigue el enfoque de clasificación nominal empleado en el estudio revisado.

5.3.4. División del Dataset y Validación

Después del preprocesamiento, el conjunto de datos deberá dividirse para realizar el entrenamiento y la evaluación del modelo. Se propone utilizar una parte de los datos para el entrenamiento y otra parte independiente para evaluar su comportamiento. Como referencia, el estudio de minería de datos revisado utilizó una división de 66 % para entrenamiento y 33 % para medir la precisión del modelo (Treviño Cansino, Alcorta García, Espinoza Fraire, Sáenz Esqueda, & Lozoya Vélez, 2018).

Para la propuesta, también será importante verificar que las categorías "SÍ_CUMPLE" y "NO_CUMPLE" estén representadas adecuadamente tanto en el entrenamiento como en la evaluación. Esta consideración resulta especialmente importante porque uno de los estudios revisados presentó un desequilibrio considerable entre ambas clases, con 102 casos de cumplimiento frente a solamente 4 casos de incumplimiento. Por esta razón, además de dividir los datos, se propone utilizar técnicas de validación que permitan comprobar que el comportamiento del modelo no dependa únicamente de una distribución específica de los registros.

5.3.5. Entrenamiento del Modelo de IA

Una vez preparado el dataset, se procederá al entrenamiento del modelo de Inteligencia Artificial. Para esta propuesta se plantea utilizar una Red Neuronal Artificial de tipo Perceptrón Multicapa (MLP), debido a que esta arquitectura ya ha sido utilizada en los estudios analizados para trabajar

con variables relacionadas con el tratamiento de aguas residuales. En el estudio sobre turbiedad se utilizó una arquitectura multicapa alimentada hacia adelante, con entrenamiento mediante propagación hacia atrás (feedforward-backpropagation) (González-Salcedo & García-Núñez, 2020).

Para la propuesta, la capa de entrada recibiría las variables seleccionadas de calidad del agua. Las capas ocultas procesarían las relaciones entre dichas variables, y la capa de salida generaría la clasificación correspondiente. El entrenamiento buscaría que la red neuronal aprenda la relación existente entre las características del agua y la condición final de calidad; una vez entrenado, el modelo podrá recibir nuevos datos y generar una predicción sobre la categoría de calidad esperada.

La arquitectura definitiva, el número de neuronas, las funciones de activación y los parámetros de entrenamiento deberán determinarse experimentalmente durante el desarrollo del modelo, utilizando los resultados obtenidos en la etapa de validación.




Figura 2. Arquitectura de un Perceptrón Multicapa (Calvo, 2018)

5.3.6. Evaluación del Modelo

La evaluación permitirá determinar si el modelo desarrollado puede realizar predicciones de manera adecuada sobre datos que no fueron utilizados durante su entrenamiento. Para la clasificación de la calidad del agua se propone analizar las siguientes métricas:

- **Exactitud (Accuracy):** proporción general de predicciones correctas.
- **Precisión (Precision):** proporción de predicciones positivas que realmente corresponden a la categoría evaluada.
- **Recall:** capacidad del modelo para identificar correctamente los casos pertenecientes a una determinada categoría.

- **Matriz de confusión:** permite observar la cantidad de predicciones correctas e incorrectas para cada categoría.

El uso de diferentes métricas resulta importante debido a que la exactitud por sí sola puede ocultar problemas cuando existe un desequilibrio entre las clases. Esto se observó en uno de los estudios revisados, donde el modelo obtuvo una exactitud global del 98.1 %, pero presentó un recall de apenas 50 % para la categoría "No Cumple" (Bernal, Simental Martínez, & Cortes Martínez, 2026). Por ello, en la propuesta se dará especial atención a la capacidad del modelo para detectar correctamente los casos clasificados como "NO_CUMPLE", ya que esta información resulta relevante para el control de la calidad del agua.

5.3.7. Predicción y Clasificación de la Calidad del Agua

Una vez entrenado y evaluado el modelo, se propone utilizarlo para analizar nuevos registros provenientes de la planta de tratamiento. El funcionamiento general sería el siguiente:

Datos del agua residual → Preprocesamiento → Modelo de IA → Predicción de parámetros → Clasificación de calidad → SÍ_CUMPLE / NO_CUMPLE

El sistema recibiría los valores correspondientes a las variables de entrada y procesaría esta información mediante el modelo entrenado. Posteriormente, produciría una clasificación de la calidad esperada. Cuando sea posible, el sistema también podría mostrar los valores estimados de determinados parámetros, permitiendo conocer qué variables están asociadas con el resultado obtenido.

Este enfoque combina dos de las aplicaciones identificadas en los estudios revisados: por una parte, la predicción de variables de calidad, como la turbiedad, mediante redes neuronales; y por otra, la clasificación del cumplimiento mediante categorías nominales como "SÍ_CUMPLE" y "NO_CUMPLE".

5.3.8. Implementación Futura del Sistema

Como etapa futura, el modelo podría integrarse a un sistema de monitoreo de una planta de tratamiento para recibir periódicamente los valores de los parámetros de calidad y generar predicciones de manera automática. La implementación podría funcionar como un sistema de apoyo para los responsables de la planta, proporcionando información sobre el comportamiento esperado de la calidad del agua y generando una alerta cuando el modelo identifique una posible condición de incumplimiento.

Además, los antecedentes revisados muestran que los modelos de Inteligencia Artificial pueden utilizarse para realizar simulaciones y apoyar la optimización de procesos de tratamiento. En el estudio de turbiedad, por ejemplo, las redes neuronales permitieron simular diferentes condiciones y generar cartas de optimización relacionadas con la dosificación de productos utilizados en el tratamiento (González-Salcedo & García-Núñez, 2020). Por lo tanto, una implementación futura podría ampliar el sistema para que, además de clasificar la calidad del agua, proporcione información útil para analizar las condiciones de operación del tratamiento.

La implementación deberá mantenerse como una herramienta complementaria a los métodos convencionales. Los resultados generados por el modelo deberán contrastarse con mediciones reales y análisis de laboratorio antes de utilizarse como apoyo para decisiones operativas. De esta manera, la Inteligencia Artificial funcionaría como un mecanismo adicional de monitoreo, predicción y apoyo a la toma de decisiones dentro del sistema de tratamiento.

5.4. Impacto Potencial de esta Solución en el Medio Ambiente

La implementación de un sistema de Inteligencia Artificial para el control y predicción de la calidad de las aguas residuales podría generar un impacto ambiental positivo al mejorar la capacidad de monitorear, analizar y anticipar el comportamiento de diferentes parámetros relacionados con el proceso de tratamiento. En los estudios analizados se demuestra que variables como la DBO, DQO, pH, sólidos suspendidos totales, conductividad y turbiedad pueden utilizarse para desarrollar modelos capaces de identificar patrones y realizar predicciones relacionadas con la calidad del agua (Bernal, Simental Martínez, & Cortes Martínez, 2026).

Uno de los principales beneficios ambientales potenciales sería la detección anticipada de condiciones de incumplimiento en el agua tratada. La propuesta contempla que el sistema no solamente realice predicciones numéricas, sino que también clasifique los resultados mediante las categorías "SÍ_CUMPLE" y "NO_CUMPLE". Este tipo de clasificación ya ha sido utilizado en estudios de minería de datos aplicados a aguas residuales, donde diferentes variables de calidad fueron relacionadas con el cumplimiento de las condiciones establecidas para el agua tratada (Treviño Cansino, Alcorta García, Espinoza Fraire, Sáenz Esqueda, & Lozoya Vélez, 2018). La detección temprana puede contribuir a disminuir el riesgo de que agua con características inadecuadas continúe hacia etapas posteriores del proceso o sea descargada sin haber recibido el tratamiento necesario. Sin embargo, el sistema propuesto debe considerarse como una herramienta complementaria al tratamiento convencional y a las mediciones de laboratorio, y no como un sustituto de estas, debido a que los resultados de los modelos dependen de la calidad y representatividad de los datos utilizados para su entrenamiento.

Otro impacto potencial se relaciona con la optimización de los procesos de tratamiento. En un estudio basado en redes neuronales artificiales se utilizaron variables como el pH, la turbiedad del agua, la dosis de coagulante y la dosis de floculante para estimar la turbiedad resultante. El modelo obtuvo un coeficiente de correlación superior a 0.99 entre los valores experimentales y los estimados, por lo que fue considerado adecuado para realizar estimaciones y como complemento de las pruebas experimentales (González-Salcedo & García-Nuñez, 2020). Este tipo de aplicación puede tener importancia ambiental debido a que permite analizar diferentes condiciones del proceso antes de realizar cambios directamente sobre el tratamiento; en el estudio mencionado, las simulaciones permitieron generar gráficos de optimización y analizar el comportamiento de la turbiedad ante diferentes dosis de los productos empleados durante la coagulación y la floculación. Además, se observó que la utilización de un catalizador biológico permitió disminuir la turbiedad de salida y trabajar con una menor cantidad de catalizador, buscando optimizar las dosis de coagulante y floculante (González-Salcedo & García-Nuñez, 2020).

Por lo tanto, una aplicación de este principio dentro de la propuesta podría ayudar a identificar condiciones de operación que favorezcan un tratamiento más eficiente. No obstante, los documentos analizados no proporcionan una cantidad específica de reducción de productos químicos, energía o residuos para el sistema propuesto, por lo que estos beneficios deben considerarse como impactos potenciales y no como reducciones ambientales ya comprobadas.

Otro aspecto importante es el aprovechamiento del agua tratada. Un tratamiento eficiente puede favorecer la posibilidad de reutilizar las aguas residuales tratadas para actividades como el riego, siempre que sus características sean adecuadas para el uso correspondiente. En el estudio de modelado predictivo se consideraron diferentes parámetros de calidad, entre ellos la conductividad, la relación de adsorción de sodio, el carbonato de sodio residual, el fósforo y el boro, como elementos relacionados con la evaluación del agua destinada a este tipo de aprovechamiento (Bernal, Simental Martínez, & Cortes Martínez, 2026). Desde esta perspectiva, un sistema de IA que facilite el seguimiento de las variables de calidad podría proporcionar información útil para determinar cuándo las condiciones del agua tratada requieren atención y cuándo los resultados se encuentran dentro de los criterios establecidos, aunque la decisión de reutilización tendría que mantenerse sujeta a las mediciones y criterios técnicos correspondientes.

También es importante considerar las limitaciones ambientales y técnicas del sistema. Un modelo de IA puede presentar buenos resultados generales y, al mismo tiempo, tener dificultades para identificar correctamente situaciones de incumplimiento. Por ejemplo, uno de los estudios revisados obtuvo una exactitud de clasificación del 98.1 %, pero alcanzó solamente un 50 % de sensibilidad para la categoría "No Cumple". Esto demuestra que, aunque la exactitud general del modelo puede ser elevada, todavía pueden presentarse dificultades para detectar determinados casos de incumplimiento (Bernal, Simental Martínez, & Cortes Martínez, 2026). Por esta razón, para una futura implementación sería necesario evaluar el modelo mediante diferentes indicadores de desempeño y prestar especial atención a la identificación de los casos "NO_CUMPLE", además de mantener actualizada la base de datos con información representativa de las condiciones reales de operación de la planta.



Figura 3. Planta de aguas residuales de JAPAC en Culiacán Norte (CuliacanDigital, 2023)

En términos generales, el impacto ambiental potencial de la solución propuesta se concentra en mejorar el monitoreo de las aguas residuales, facilitar la detección de posibles incumplimientos, apoyar la optimización de los procesos de tratamiento y generar información que pueda favorecer el aprovechamiento del agua tratada. Los estudios revisados muestran que las redes neuronales artificiales y la minería de datos pueden utilizarse para realizar predicciones, identificar patrones y clasificar condiciones relacionadas con la calidad del agua (González-Salcedo & García-Núñez, 2020; Treviño Cansino, Alcorta García, Espinoza Fraire, Sáenz Esqueda, & Lozoya Vélez, 2018). De esta manera, la propuesta busca que la Inteligencia Artificial funcione como una herramienta de apoyo para la toma de decisiones dentro del tratamiento de aguas residuales, contribuyendo a un control más oportuno de la calidad del agua y a una gestión más eficiente del proceso, siempre manteniendo la validación mediante mediciones reales y procedimientos convencionales de control de calidad.

6. Agenda

A continuación, se presenta el cronograma de actividades del proyecto realizado el mes de Septiembre, comparando lo esperado (E) frente a lo realizado (R) durante el periodo de desarrollo. Las marcas se presentan como referencia y pueden ajustarse a las fechas reales de trabajo del equipo.,

Evento	Actividad	E/R	4	5	6	7	8	9	10	11	12	13	14	15	16	17
1	Obtención de Información	E	X	X	X											
		R	X	X	X											
2.1	Objetivo General	E		X	X											
		R		X	X											
2.2	Objetivos Específicos	E			X	X										
		R			X	X										
3	Justificación	E				X	X									
		R				X	X									
4	Alcance	E					X	X								
		R					X	X								
5	Desarrollo	E						X	X	X	X	X				
		R						X	X	X	X	X	X			
6	Agenda	E											X			
		R												X		
7	Introducción	E												X		
		R												X	X	
8	Conclusión	E													X	X
		R													X	X

E = Esperado R = Real

7. Conclusiones

El desarrollo de esta investigación demuestra que la integración de herramientas analíticas y modelos basados en inteligencia artificial representa una alternativa viable y necesaria frente a las limitaciones de los métodos tradicionales de monitoreo ambiental. A lo largo del proyecto se definieron las variables fisicoquímicas relevantes (DBO, DQO, pH, SST, conductividad y turbiedad), se propuso una metodología para construir y preprocesar un dataset a partir de registros históricos, y se planteó el uso de una Red Neuronal Artificial de tipo Perceptrón Multicapa capaz de clasificar el efluente tratado en las categorías "SÍ_CUMPLE" y "NO_CUMPLE", cumpliendo así con los objetivos específicos planteados al inicio del trabajo.

La revisión de los antecedentes también permitió identificar una limitación importante que deberá atenderse durante la implementación: el desequilibrio entre clases puede hacer que un modelo con una exactitud global elevada, aun así, tenga un desempeño deficiente para detectar los casos de incumplimiento, que son precisamente los más relevantes desde el punto de vista ambiental. Por ello, la propuesta enfatiza el uso de métricas complementarias —precisión, recall y matriz de confusión— y de técnicas de validación que reduzcan la dependencia del modelo respecto a una distribución específica de los datos.

La estructuración de un sistema enfocado en el procesamiento de parámetros fisicoquímicos clave no solo optimiza la gestión y el cumplimiento normativo de los cuerpos hídricos, sino que también reduce significativamente los tiempos y costos operativos asociados al muestreo convencional. En consecuencia, la propuesta desarrollada consolida una base tecnológica robusta, capaz de transformar datos complejos en información precisa y oportuna para la toma de decisiones en la ingeniería ambiental. Como trabajo futuro, se contempla la integración del modelo con sensores y sistemas de hardware que permitan automatizar el monitoreo en tiempo real, así como la validación continua de sus resultados frente a mediciones de laboratorio, de manera que la Inteligencia Artificial se consolide como un mecanismo confiable de apoyo dentro del tratamiento de aguas residuales.

8. Bibliografía

- Bernal, L. A., Simental Martínez, A. I., & Cortes Martínez, F. (2026, abril). Modelado predictivo de variables de calidad en aguas residuales mediante inteligencia artificial. *Revista Ibero Ciencias*. <https://revistaiberociencias.org/index.php/multidisciplinar/article/view/974/2915>
- Calvo, D. (2018, 8 de diciembre). *Perceptrón multicapa – Red neuronal*. Diego Calvo. <https://www.diegocalvo.es/perceptron-multicapa/>
- CuliacanDigital. (2023, 5 de octubre). *Sinaloa es líder en materia de tratamiento de aguas residuales a nivel nacional*. <https://culiacandigital.mx/sinaloa-es-lider-en-materia-de-tratamiento-de-aguas-residuales-a-nivel-nacional/>
- González-Salcedo, L. O., & García-Nuñez, J. B. (2020). *Elaboración de un modelo neuronal artificial para la estimación de turbiedad y proposición de dosificaciones en el tratamiento de aguas residuales de la industria avícola*. Dialnet. <https://dialnet.unirioja.es/servlet/articulo?codigo=7278572>
- Treviño Cansino, A., Alcorta García, M. A., Espinoza Fraire, A. T., Sáenz Esqueda, J. A., & Lozoya Vélez, J. G. (2018, 7 de septiembre). *Reglas para predecir el cumplimiento de la calidad del agua residual en una planta tratadora con minería de datos*. Journal Iberamia. <https://journal.iberamia.org/index.php/intartif/article/view/168/64>
- Secretaría de Medio Ambiente y Recursos Naturales [SEMARNAT]. (2013). Compendio de estadísticas ambientales 2013. https://apps1.semarnat.gob.mx:8443/dgeia/compendio_2013/dgeiawf.semarnat.gob.mx_8080/ibi_apps/WFServlet28b9.html
- Camacho-Ballesteros, A., Ortega-Escobar, H. M., Sánchez-Bernal, E. I., & Can-Chulim, Á. (2020). Indicadores de calidad físico-química de las aguas residuales del estado de Oaxaca, México. *Terra Latinoamericana*, 38(2), 361-375. https://www.scielo.org.mx/scielo.php?script=sci_arttext&pid=S0187-57792020000300361
- Quiñones Huatangari, L., Ochoa Toledo, L., Gamarra Torres, O., Bazán Correa, J., Delgado Soto, J., & Kemper Valverde, N. (2020). Red neuronal artificial para estimar un índice de calidad de agua. *Enfoque UTE*, 11(2), 109-122. https://scielo.senescyt.gob.ec/scielo.php?pid=S1390-65422020000200109&script=sci_arttext